

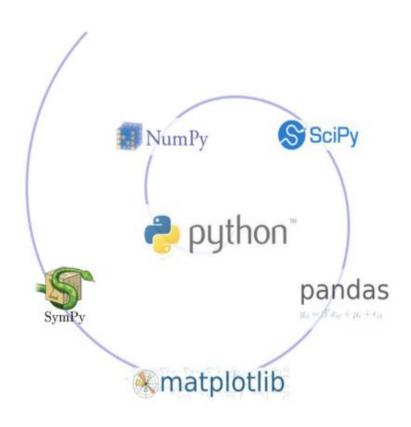
메디치소프트 기술연구소

Kaggle 영화 추천 시스템



AI EXPERT-RECOMMENDER SYSTEMS

목차



Simple Recommender
Content Based Recommender
Collaborative Filtering
Hybrid Engine



이론

평점 Ranking 기반 추천 시스템

보조자료

movie_recsys.py

✓ 개념

- 영화 인기와 장르를 기반으로 모든 사용자에게 적용할 수 있는 일반화된 추천 알고리즘
- 대중적이고 호평을 받는 영화가 일반 관객들에게 호감일 확률이 더 높을 것이라는게 기본 아이디어
- 사용자, 개인 맟춤이 아님
- 관람객수와 인기에 따라 영화순위를 정하고 높은 순서대로 추천해주는 방식
- ✓ 수식 (영화 차트 사이트 IMDB 수식)

Weighted Rating (WR) =
$$\left(\frac{v}{v+m} \times R\right) + \left(\frac{m}{v+m} \times C\right)$$

- v: 영화 득표수

- m: 차트에 나열되기 위한 최소한의 투표수 (95%)

- R: 영화의 평균 평점

- C:전체 차트의 평균 평점

- Weighted Rating을 영화별로 구하고 이를 정렬



알고리즘 평점 Ranking 기반 추천 시스템

보조자료

- vote_average, vote_count, popularity, genre 변수를 통해 Simple Recommender 구현
- -literal_eval: literal 형태의 자료형을 실행 가능한 형태로 변환해주는 함수

Descri	ption		Code
✓ movies_metadata.csv 변수 - adult : 성인영화 여부 - belongs_to_collection : id, name, p - budget : 예산 - genres : 장르 - homepage : 홈페이지 - id : 영화 id - imdb_id : imdb 사이트 영화 id - orginal_language : 언어 - orginal_title : 제목 - overview : 맛보기 - popularity : 인기도 - poster_path : poster - production_company : 제작사 - production_countries : 제작한 나라 - release_date : 개봉 날짜 - revenue : 수입 - runtime : 상영시간 - spoken_languages : 언어 - status : 상태 - tagline : tag - title : 제목 - video : video - vote_averge : 평점 - vote_count : 평점 수		me.DataFrame'> es, 0 to 45465 columns): 45466 non-null object 45455 non-null object 45455 non-null object 45466 non-null object 45461 non-null object 45463 non-null object 45463 non-null object 45460 non-null object 45460 non-null object 45379 non-null object 45460 non-null object	<pre>import pandas as pd import numpy as np from ast import literal_evalimport warnings; warnings.simplefilter('ignore') md = pd. read_csv('/data/movies_metadata.csv') md.info() md = md.drop([19730, 29503, 35587])</pre>



알고리즘 literal 형태 genre 전처리

보조자료

- vote_average, vote_count, popularity, genre 변수를 통해 Simple Recommender 구현
- literal_eval: literal 형태의 자료형을 실행 가능한 형태로 변환해주는 함수
- -isinstance(x, type) : x가 type형인지 여부

Description	Code
✓ 실행 결과 - genres 변수 [{'id': 16, 'name': 'Animation'}, {'id': 35, ' [{'id': 12, 'name': 'Adventure'}, {'id': 14, ' [{'id': 10749, 'name': 'Romance'}, {'id': 35, [{'id': 35, 'name': 'Comedy'}, {'id': 18, 'nam [{'id': 35, 'name': 'Comedy'}] [{'id': 28, 'name': 'Action'}, {'id': 80, 'nam [{'id': 35, 'name': 'Comedy'}, {'id': 10749, '	# genres 추출 - 여러 요소를 갖는 리스트 형태 print(md['genres'])
- name 추출 후 리스트 변환 [Animation, Comedy, Family] [Adventure, Fantasy, Family] [Romance, Comedy] [Comedy, Drama, Romance] [Comedy] [Action, Crime, Drama, Thriller]	<pre>md['genres'] = md['genres'].fillna('[]').apply(literal_eval).apply(lambda x: [i['name'] for i in x] if isinstance(x, list) else []) print(md['genres'])</pre>



알고리즘 WR 수식에서 C, m 구하기

보조자료

- C는 영화 전체 평균, m은 최소한 평점을 받아야 하는 사람 수
- notnull(): null인 것은 False, null이 아닌 것은 True
- quantile(n): 전체 분포에서 상위 n분위에 해당하는 값

Description	Code
✓ 실행 결과 - vote_count 변수	# null 값 제외하고 int 자료형으로 변경 후 평균 구하기 => C print(md['vote_count'].head()) print(md['vote_average'].head()) vote_counts = md[md['vote_count'].notnull()]['vote_count'].astype('int') vote_averages = md[md['vote_average'].notnull()]['vote_average'].astype ('int') C = vote_averages.mean() print(C)
- m 값 434.0	# 최소한 95%이상의 사람의 평점을 받은 영화여야 됨 => m m = vote_counts.quantile(0.95) print(m)



알고리즘 year 변수 생성 및 C 이상 data 추출

보조자료

movie_recsys.py

- to_datetime : 날짜형식의 자료형으로 변경

- split(x) : 'x' 문자열 기준 나누기

- np.nan: nan 값

Description	Code
✓ 실행 결과 - release_date 변수 -> year 변수 □ 1995-10-30 □ 1995 1 1995-12-15 □ 1 1995 2 1995-12-22 □ 2 1995 3 1995-12-22 □ 3 1995 4 1995-02-10 □ 4 1995 5 1995-12-15 □ 5 1995	# 년도만 추출 print(md['release_date']) md['year'] = pd.to_datetime(md['release_date'], errors='coerce').apply(lambda x: str(x).split('-')[0] if x != np.nan else np.nan) print(md['year']) # 평점 count 434 이상 & null값 아닌 데이터셋 추출 print(md.shape)
- md.shape	qualified = md[(md['vote_count'] >= m) & (md['vote_count'].notnull()) &
(45466, 25)	<pre>(md['vote_average'].notnull())][['title', 'year', 'vote_count', 'vote_average', 'popularity', 'genres']] qualified['vote_count'] = qualified['vote_count'].astype('int')</pre>
- qualified.shape	
(2274, 6)	qualified['vote_average'] = qualified['vote_average'].astype('int')
	print(qualified.shape)



알고리즘 WR 기준 data sorting 후 추천

보조자료

- WR 수식 기반으로 단순 추천 알고리즘 구현
- 영화 인기 기반 추천이기 때문에 모든 사용자에게 동일한 영화 순위 추천
- 인셉션, 다크나이트 등 을 봤을 때 genres, directors의 영향이 강한것으로 보임

		Desc	ription		Code
실행 결과	•	wate count wat	te_average popularit	denres wr	# weighted rating 구하는 함수 def weighted_rating(x):
15480	Inception 2010	14075	8 29.108		
12481	The Dark Knight 2008	12269	8 123.16		v = x['vote_count']
2879	Interstellar 2014	11187	8 32.213		$R = x['vote_average']$
843	Fight Club 1999	9678	8 63.869	[Drama] 7.881753	K = X[Vote_average]
863 The Lord of the Rin	gs: The Fellowship of the Ring 2001	8892	8 32.070	7 [Adventure, Fantasy, Action] 7.871787	return (v/(v+m) * R) + (m/(m+v) * C)
292	Pulp Fiction 1994	8670	8 140.9	5 [Thriller, Crime] 7.868660	(V) (V) (V) (V) (V) (V) (V)
314	The Shawshank Redemption 1994	8358	8 51.645	4 [Drama, Crime] 7.864000	
000 The Lord of the	Rings: The Return of the King 2003	8226	8 29.324	4 [Adventure, Fantasy, Action] 7.861927	
351	Forrest Gump 1994	8147	8 48.307	[Comedy, Drama, Romance] 7.860656	qualified['wr'] = qualified.apply(weighted_rating, axis:
314 The Lord	of the Rings: The Two Towers 2002	7641	8 29.423	[Adventure, Fantasy, Action] 7.851924	
256	Star Wars 1977	6778	8 42.149	7 [Adventure, Action, Science Fiction] 7.834205	qualified = qualified.sort_values('wr',
25	Back to the Future 1985	6239	8 25.778	5 [Adventure, Comedy, Science Fiction, Family] 7.820813	according - Folso) boad(250)
334	The Godfather 1972	6024	8 41.109	B [Drama, Crime] 7.814847	ascending= False).head(250)
154	The Empire Strikes Back 1980	5998	8 19.47 8 18.457		
					print(qualified.head(15))



알고리즘 genre 변수 추가 보조자료 movie_recsys.py

- stack(): 여러 값을 하나의 열로 재구조화
- join : 인덱스 기준 두개의 dataframe 병합

Description					
_	Ad	elting 형태 imation Comedy Family venture Fantasy Family	태로 변경		
	nd와 joing 결	보고			
n		vote_average	vote_count	year	genre
0			vote_count 5415.0	year 1995	genre Animation
_	title	vote_average			
0	title Toy Story	vote_average	5415.0	1995 1995	Animation
0	title Toy Story Toy Story	vote_average 7.7 7.7	5415.0 5415.0	1995 1995	Animation Comedy
0	Toy Story Toy Story Toy Story	vote_average 7.7 7.7 7.7	5415.0 5415.0 5415.0	1995 1995 1995 1995	Animation Comedy Family
0 0 0	Toy Story Toy Story Toy Story Jumanji	vote_average 7.7 7.7 7.7 6.9	5415.0 5415.0 5415.0 2413.0	1995 1995 1995 1995	Animation Comedy Family Adventure
0 0 0 1 1	Toy Story Toy Story Toy Story Jumanji Jumanji	7.7 7.7 7.7 6.9 6.9	5415.0 5415.0 5415.0 2413.0 2413.0	1995 1995 1995 1995 1995	Animation Comedy Family Adventure Fantasy
0 0 0 1 1 1 2	Toy Story Toy Story Toy Story Jumanji Jumanji Jumanji	7.7 7.7 7.7 6.9 6.9 6.9	5415.0 5415.0 5415.0 2413.0 2413.0 2413.0	1995 1995 1995 1995 1995 1995	Animation Comedy Family Adventure Fantasy Family
0 0 0 1 1 1 2	Toy Story Toy Story Toy Story Jumanji Jumanji Jumanji Grumpier Old Men	vote_average 7.7 7.7 7.7 6.9 6.9 6.9 6.5	5415.0 5415.0 5415.0 2413.0 2413.0 2413.0 92.0	1995 1995 1995 1995 1995 1995 1995 1995	Animation Comedy Family Adventure Fantasy Family Romance



알고리즘 ge

genre, percentile 옵션 추가

보조자료

- genre, percentile 옵션을 통해 chart 순위 재정의
- simple recommender의 단점: 모든 사람에게 같은 추천 제공, 어떤 변수가 추천에 중요 요소로 작용했는지 알 수 없음

	I	Desc	cription				Code
′ 실행	결과 title	vear	vote count	vote_average	popularity	wr	# 장르, 퍼센트 옵션 추가 def build_chart(genre, percentile=0.85):
10309	Dilwale Dulhania Le Jayenge		661	9		8.565285	<pre>df = gen_md[gen_md['genre'] == genre] vote counts =</pre>
351	Forrest Gump		8147	8		7.971357	df[df['vote_count'].notnull()]['vote_count'].astype('int')
876	Vertigo		1162	8		7.811667	vote_averages =
40251	Your Name.		1030		34.461252		df[df['vote_average'].notnull()]['vote_average'].astype('int')
							C = vote_averages.mean()
883	Some Like It Hot		835	8		7.745154	m = vote_counts.quantile(percentile)
1132	Cinema Paradiso		834	8		7.744878	qualified = df[(df['vote_count'] >= m) & (df['vote_count'].notnu
19901	Paperman	2012	734	8	7.19863	7.713951	& (df['vote_average'].notnull())][
37863	Sing Street	2016	669	8	10.672862	7.689483	['title', 'year', 'vote_count', 'vote_average', 'popularity']]
882	The Apartment	1960	498	8	11.9943	7.599317	qualified['vote_count'] = qualified['vote_count'].astype('int')
38718	The Handmaiden	2016	453	8	16.727405	7.566166	qualified['vote_average'] = qualified['vote_average'].astype('int')
3189	City Lights	1931	444	8	10.8915	7.558867	
24886	The Way He Looks	2014	262	8	5.71127	7.331363	qualified['wr'] = qualified.apply(
45437	In a Heartbeat	2017	146	8	20.82178	7.003959	lambda x: (x['vote_count'] / (x['vote_count'] + m) * x['vote_average']) + (m / (m + x['vote_count']) * C),
1639	Titanic	1997	7770	7	26.8891	6.981546	axis=1)
19731	Silver Linings Playbook	2012	4840	7	14.4881	6.970581	qualified = qualified.sort_values('wr', ascending=False).head(250)
	-						return qualified print(build_chart('Romance').head(15))



이론

평점 Ranking 기반 추천 시스템

보조자료

movie_recsys.py

✓ 개념

- 사용자 혹은 아이템에 대한 프로필 데이터를 가지고 1)내가 좋아했던 아이템과 비슷한 유형의 아이템을 추천하거나 2)나와 비슷한 유형의 사람이 좋아하는 아이템을 추천
- 사용자 프로필(성별, 연령대, 지역 등) 정보를 토대로 유사한 그룹의 사용자가 선호하는 영화 추천
- 영화 프로필(장르, 배우, 감독 등) 정보를 토대로 사용자가 기존에 좋아했던 영화와 유사한 그룹의 영화를 추천
- 단점: 데이터 셋 구성의 어려움, 주관성 개입
- ✓ movie recommender 적용
- 영화 사이의 유사도 행렬 계산
- 사용자가 선호하는 영화와 가장 유사한 영화 추천
- movie metadata, content 활용
 - (1) overviews, taglines 등 description 기반 추천 (Tf-idf 알고리즘 사용)
 - (1) cast, crew, keywords, genre 등 metadata 기반 추천 (CounterVector 알고리즘 사용)

* TF-IDF Vector

: 해당문서에서 각 토큰이 얼마나 중요한지에 대한 가중치

$$w_{x,y} = tf_{x,y} \times log(\frac{N}{df_x})$$

TF-IDFTerm **x** within document **y**

 $tf_{x,y} = frequency of x in y$

 $df_{x} = number of documents containing x$

N = total number of documents

* Counter Vector

: 해당문서에서 각 토큰 출현 횟수

	very	sad	fun	
Doc1	1	2	0	•••
Doc2	0	0	1	•••
	•••	•••	•••	•••



이론

간단 예제

보조자료

movie_recsys.py

- ✓ 코사인 유사도
- 두 벡터 간의 코사인 각도를 이용하여 구할 수 있는 두 벡터의 유사도를 의미
- ✓ movie recommender 적용
- 영화 사이의 유사도 행렬 계산
- 사용자가 선호하는 영화와 가장 유사한 영화 추천
- movie metadata, content 활용
 - (1) overviews, taglines 등 description 기반 추천 (Tf-idf 알고리즘 사용)
 - (1) cast, crew, keywords, genre 등 metadata 기반 추천 (CounterVector 알고리즘 사용)

* TF-IDF Vector

: 해당문서에서 각 토큰이 얼마나 중요한지에 대한 가중치

$$w_{x,y} = tf_{x,y} \times log(\frac{N}{df_x})$$

TF-IDFTerm **x** within document **y**

 $tf_{x,y}$ = frequency of x in y

 $df_x = number of documents containing x$

N = total number of documents

* Counter Vector

: 해당문서에서 각 토큰 출현 횟수

	very	sad	fun	•••
Doc1	1	2	0	•••
Doc2	0	0	1	•••
•••	•••		•••	



알고리즘 (1) description 정보 기반 추천 (1/3)

보조자료

- small data 사용
- tagline, overview를 합쳐 description 변수 생성

	De	scription	Code
	행 결과 nk_small.head() movield imdbld tmdbld 1 114709 862.0 2 113497 8844.0	- smd2.shape (9099, 25) - 변수 설명	links_small = pd.read_csv('/data/links_small.csv') print(links_small.head()) # small data 사용 links_small = links_small[links_small['tmdbld'].notnull()]['tmdbld'].asty
2 3 4 SI	3 113228 15602.0 4 114885 31357.0 5 113041 11862.0 md2[['description']]	 movield : 영화 고유 키 imdbld : imdb상의 고유 키 tmdbld : tmdb상의 고유 키 description 	<pre>pe('int') md['id'] = md['id'].astype('int') smd2 = md[md['id'].isin(links_small)] print(smd2.shape)</pre>
0	Led by Woody, Andy's	toys live happily in his	# 영화 text 정보 column 생성
1	When siblings Judy and F	eter discover an encha	smd2['tagline'] = smd2['tagline'].fillna('')
2 A family wedding reignites the ancient feud be		ites the ancient feud be	smd2['description'] = smd2['overview'] +
3	Cheated on, mistreated ar	nd stepped on, the wom	<pre>smd2['tagline'] smd2['description'] = smd2['description'].fillna('') print(smd2[['description']])</pre>
4	Just when George Banks	has recovered from his	
5	Obsessive master thief,	Neil McCauley leads a	



알고리즘

(1) description 정보 기반 추천(2/3)

보조자료

- TfidfVectorizer(analyzer, ngram_Range, min_df, stop_words) : 형태소 분석방법, ngram 기준, 최소 빈도, 불용어 처리
- -linear_kernel : 두 매트릭스에서 코사인유사도 행렬 생성

Description		Code
✓ 실행 결과		from sklearn.feature_extraction.text import
- tfidf_matrix.shape		TfidfVectorizer
(9099, 268124)		from sklearn.metrics.pairwise import linear_kernel cosine_similarity
- cosine_sim		_ ,
array([[1. , 0.00680476, 0. ,, 0. , 0.00344913,		# tfidf 적용
[0.00680476, 1. , 0.01531062,, 0.00357057, 0.00762326,		tf = TfidfVectorizer(analyzer='word',ngram_range=(1,
0. 1, [0. , 0.01531062, 1. ,, 0. , 0.00286535, 0.004721551.		2),min_df=0, stop_words='english')
		tfidf_matrix = tf.fit_transform(smd['description'])
[0. , 0.00357057, 0. ,, 1. , 0.07811616, 0.],		
- indices		print(tfidf_matrix.shape)
title Toy Story	0	cosine_sim = linear_kernel(tfidf_matrix, tfidf_matrix)
Jumanji	1	cosine_sim = imedi_kernei(thai_matrix, thai_matrix)
Grumpier Old Men Waiting to Exhale	2 3	print(cosine_sim)
Father of the Bride Part II	4	print(cosine_sim)
Heat	5	smd = smd.reset_index()
Sabrina Tom and Huck	6 7	titles = smd['title']
Sudden Death	8	indices = pd.Series(smd.index, index=smd['title'])
Golden Eye	9	· · · · · · · · · · · · · · · · · · ·
The American President	10	print(indices)



알고리즘 (1) description 정보 기반 추천 (3/3)

보조자료

Description	Code		
▼ 실행 결과 - "The Godfather"와 유사한 영화 title vote_count vote_average year	# 영화 제목이 들어오면 해당 열에서 가장 유사도 높은 순으로 정렬 후 인덱스 쁩기 # contents based recommender def get_recommendations_based_description(title, smd2): tf = TfidfVectorizer(analyzer='word', ngram_range=('2), min_df=0, stop_words='english') tfidf_matrix = tf.fit_transform(smd2['description']) cosine_sim = linear_kernel(tfidf_matrix, tfidf_matrix) smd2 = smd2.reset_index() indices = pd.Series(smd2.index, index=smd2['title']) idx = indices[title] sim_scores = list(enumerate(cosine_sim[idx])) sim_scores = sorted(sim_scores, key=lambda x: x[1], reverse=True) sim_scores = sim_scores[1:31] movie_indices = [i[0] for i in sim_scores] return smd2.iloc[movie_indices][['title', 'vote_count', 'vote_average', 'year']] print(get_recommendations_based_description('The Godfather', smd2).head(10))		



알고리즘 (2) metadata 정보 기반 추천 (1/8)

보조자료

movie_recsys.py

- credits, keywords 데이터와 md데이터 merge

Descrip	tion	Code
	crew id t_id': '52fe4284c3a36847f8024f49', 'de 862 it_id': '52fe44bfc3a36847f80a7cd1', 'de 8844	<pre>credits = pd.read_csv('/data/credits.csv') keywords = pd.read_csv('/data/keywords.csv') print(credits.head())</pre>
2 [{'cast_id': 2, 'character': 'Max Goldman', 'c [{'credit. 3 [{'cast_id': 1, 'character': "Savannah 'Vannah [{'credit. 4 [{'cast_id': 1, 'character': 'George Banks', ' [{'credit.	_id': '52fe44779251416c91011acb', 'de 31357	print(keywords.head())
• cast : cast(배우) 정보 • crew: crew(제작진) 정보 • id : 영화 고유 키		<pre>keywords['id'] = keywords['id'].astype('int') credits['id'] = credits['id'].astype('int') md['id'] = md['id'].astype('int')</pre>
keywords.head keywo	rds	print(md.shape)
0 862 [{'id': 931, 'name': 'jealousy'}, {'id': 429 1 8844 [{'id': 10090, 'name': 'board game'}, {'id': 2 15602 [{'id': 1495, 'name': 'fishing'}, {'id': 1239 3 31357 [{'id': 818, 'name': 'based on novel'}, {'id': 1599, 4 11862 [{'id': 1009, 'name': 'baby'}, {'id': 1599,	• id : 영화 고유 키 2 • keywords : 영화 1	# credits, keywords emrge md = md.merge(credits, on='id') md = md.merge(keywords, on='id')
md.shape (45463, 25)	- smd.shape (9219, 28)	<pre>smd = md[md['id'].isin(links_small)] print(smd.shape)</pre>



알고리즘 (2) metadata 정보 기반 추천 (2/8)

보조자료

movie_recsys.py

- cast 변수 배우 이름 추출 및 전처리

	Description		Code
✓ 실행 - sma	결과 d[['cast', 'cast_size']]		<pre>smd['cast'] = smd['cast'].apply(literal_eval) smd['cast_size'] = smd['cast'].apply(lambda x: len(x))</pre>
	cast	cast_size	# 배우 3명까지 추출
0	[tomhanks, timallen, donrickles]	13	smd['cast'] = smd['cast'].apply(lambda x: [i['name'] for
1	[robinwilliams, jonathanhyde, kirstendunst]	26	i in x] if isinstance(x, list) else [])
2	[waltermatthau, jacklemmon, ann-margret]	7	smd['cast'] = smd['cast'].apply(lambda x: x[:3] if
3	[whitneyhouston, angelabassett, lorettadevine]	10	len(x) >= 3 else x)
4	[stevemartin, dianekeaton, martinshort]	12	# 배우 이름 전처리 - 소문자화, 띄어쓰기 제거
5	[alpacino, robertdeniro, valkilmer]	65	smd['cast'] = smd['cast'].apply(lambda x:
6	[harrisonford, juliaormond, gregkinnear]	57	[str.lower(i.replace(" ", "")) for i in x])
7	[jonathantaylorthomas, bradrenfro, rachaelleig	7	print(cmd[['cast' 'cast size']])
8	[jean-claudevandamme, powersboothe, dorianhare	6	print(smd[['cast', 'cast_size']])
9	[piercebrosnan, seanbean, izabellascorupco]	20	



알고리즘 (2) metadata 정보 기반 추천 (3/8)

보조자료

- crew변수에서 감독 추출
- 감독이름에 가중치를 주기 위해 3번 반복 리스트 만들어서 director 변수 생성

	Description		Code
실행	director	crew_size	<pre>smd['crew'] = smd['crew'].apply(literal_eval) smd['crew_size'] = smd['crew'].apply(lambda x: len(x))</pre>
0	[johnlasseter, johnlasseter, johnlasseter]	106	# 감독열 추가
1	[joejohnston, joejohnston, joejohnston]	16	<pre>def get_director(x):</pre>
2	[howarddeutch, howarddeutch, howarddeutch]	4	for i in x:
3	[forestwhitaker, forestwhitaker, forestwhitaker]	10	if i['job'] == 'Director':
4	[charlesshyer, charlesshyer, charlesshyer]	7	return i['name'] return np.nan
5	[michaelmann, michaelmann, michaelmann]	71	Tetarri rip.nan
6	[sydneypollack, sydneypollack, sydneypollack]	53	smd['director'] = smd['crew'].apply(get_director)
7	[peterhewitt, peterhewitt, peterhewitt]	4	smd['director'] =
8	[peterhyams, peterhyams, peterhyams]	9	smd['director'].astype('str').apply(lambda x: str.lower(x.replace(" ", "")))
9	[martincampbell, martincampbell, martincampbell]	46	
			# 가중치로 3회 넣음 smd['director'] = smd['director'].apply(lambda x: [x,x, x]) print(smd[['director', 'crew_size']])



알고리즘 (2) metadata 정보 기반 추천 (4/8)

보조자료

- keywords 에서 출현한 각 토큰의 빈도수를 구함
- 2개 이상의 토큰 추출

Description	Code
✓ 실행 결과 - 영화별 keywords 토큰 0 jealousy toy boy toy on boy of friendship friends rivalry toy onew toy of toy comes to life board game disappearance in based on children's book ercluse giant insect - 토큰 빈도 counting - 2개 이상 토큰 추출 independent film film film woman director soom murder source duringcreditsstinger 327 based on novel solence 318 violence	<pre>smd['keywords'] = smd['keywords'].apply(literal_eval) smd['keywords'] = smd['keywords'].apply(lambda x: [i['name'] for i in x] if isinstance(x, list) else []) s = smd.apply(lambda x: pd.Series(x['keywords']),axis=1).stack().reset_index(level =1, drop=True) s.name = 'keyword' print(s) s = s.value_counts() print(s) # 12940 => 6709 print(len(s)) s = s[s > 1] print(len(s))</pre>



알고리즘 (2) metadata 정보 기반 추천 (5/8)

보조자료

- stemmer.stem(x): x 문자열을 일반형으로 변형 (ex. dogs -> dog / was -> is)
- replace(x, y) : x를 y로 대체



알고리즘 (2) metadata 정보 기반 추천 (6/8)

보조자료

- movie meta data(text) 변수 합치기
- " ".join(x) : x리스트를 " "를 연결요소를 통해 하나로 합치는 함수

실행 경	 결과	# keywords, cast, director, genres 합치기
	soup	smd['soup'] = smd['keywords'] + smd['cast'] + smd['director'] + smd['genres']
0	jealousi toy boy friendship friend rivalri boy	cmd['coup'] = cmd['coup'] apply(lambda v: ' ' ioip(v))
1	boardgam disappear basedonchildren'sbook newho	smd['soup'] = smd['soup'].apply(lambda x: ' '.join(x))
2	fish bestfriend duringcreditssting waltermatth	print(smd[['soup']])
3	basedonnovel interracialrelationship singlemot	
4	babi midlifecrisi confid age daughter motherda	
5	robberi detect bank obsess chase shoot thief h	
6	pari brotherbrotherrelationship chauffeur long	
7	jonathantaylorthomas bradrenfro rachaelleighco	
8	terrorist hostag explos vicepresid jean-claude	
9	cuba falselyaccus secretident computervirus se	



알고리즘

(2) metadata 정보 기반 추천 (7/8)

보조자료

- CountVectorizer(analyzer, ngram_range, min_df, stop_words) : 형태소 분석 방법, ngram 영역, 최소 빈도수, 불용 어 처리
- cosine_silmilarity : cosine 유사도 구해주는 함수

Description	Code
✔ 실행 결과 - "The Godfather"와 유사한 영화 title	<pre>def get_recommendations_based_metadata(title, smd): count = CountVectorizer(analyzer='word', ngram_range=(1, 2), min_df=0, stop_words='english') count_matrix = count.fit_transform(smd['soup']) cosine_sim = cosine_similarity(count_matrix, count_matrix) smd = smd.reset_index() indices = pd.Series(smd.index, index=smd['title']) idx = indices[title] sim_scores = list(enumerate(cosine_sim[idx])) sim_scores = sorted(sim_scores, key=lambda x: x[1], reverse=True) sim_scores = sim_scores[1:31] movie_indices = [i[0] for i in sim_scores] return smd.iloc[movie_indices][['title', 'vote_count', 'vote_average', 'year']] print(get_recommendations_based_metadata('The Godfather', smd).head(10))</pre>



알고리즘 (2) metadata 정보 기반 추천 (8/8)

보조자료

- simple recommender에 content based recommender 추가
- 단점: 장르를 넘어서는 추천 어려움, 개인 맞춤이 아닌 누구에게나 같은 영화 추천

	Descrip	tion			Code
√ 실행 결고 - "The D	ark Knight"와 유사한		e average year	wr	# simple reccomender 개선 def improved_recommendations(title, smd): movies = get_recommendations_based_metadata(title, smd)
7648	Inception	14075	8 2010		<pre>vote_counts = movies[movies['vote_count'].notnull()]['vote_count'].astype('int')</pre>
8613	Interstellar	11187	8 2014	7.897107	vote_averages =
6623	The Prestige	4510	8 2006	7.758148	movies[movies['vote_average'].notnull()]['vote_average'].astype('i
3381	Memento	4168	8 2000	7.740175	nt')
8031	The Dark Knight Rises	9263	7 2012	6.921448	C = vote_averages.mean()
6218	Batman Begins	7511	7 2005	6.904127	$m = vote_counts.quantile(0.60)$
1134	Batman Returns	1706	6 1992	5.846862	qualified = movies[(movies['vote_count'] >= m) & (movies['vote_count'].notnull()) &
- "Mean	Girs"와 유사한 영화				<pre>(movies['vote_average'].notnull())] qualified['vote_count'] = qualified['vote_count'].astype('int') qualified['vote average'] =</pre>
1547	The Breakfast Club	vote_count v		6.709602	qualified['vote_average'].astype('int')
390	Dazed and Confused	588		6.254682	qualified['wr'] = qualified.apply(weighted_rating, axis=1)
8883	The DUFF	1372		5.818541	qualified = qualified.sort_values('wr',
3712	The Princess Diaries	1063		5.781086	ascending= False).head(10)
4763	Freaky Friday	919	6 2003	5.757786	return qualified
6277	Just Like Heaven	595	6 2005	5.681521	print(improved_recommendations('The Dark Knight',
6959	The Spiderwick Chronicles	593	6 2008	5.680901	smd).head(10)) print(improved_recommendations('Mean Girls', smd).head(10))



3. Collaborative Filtering

이론

평점 Ranking 기반 추천 시스템

보조자료

movie_recsys.py

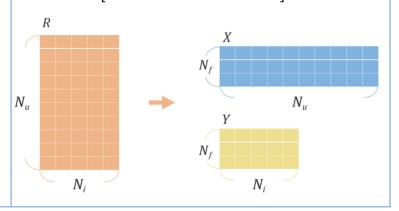
✓ 개념

- 내가 남긴 "평점 데이터"를 가지고 나와 취향이 비슷한 사람이 선호하는 아이템을 추천
- 프로필 데이터 없이, 사용자의 과거 행동 데이터를 가지고 추천 진행
- 영화의 경우 사용자가 과거에 남긴 평점을 통해 취향을 파악한 뒤 선호할
 만한 영화 추천
- ✓ dataset 특성
- Explicit Dataset : 선호와 비선호를 명확하게 구분해주는 데이터 셋, 영화 평점데이터, 상품 리뷰데이터 등
- Implicit Dataset : 선호와 비선호 구분 없이 행동 빈도수만 있는 데이터 셋, 쇼핑몰 클릭 로그, 음악 재생 빈도 등
- ✓ 알고리즘
- Neighborhood model : Explicit Dataset에 적합, pearson 상관계수를 통해 서로 비슷한 유저 혹은 아이템 찿는 기법
- Latent Fctor Model: Implicit Dataset에 적합, 사용자 평점 행렬을 사용자, 아이템 두 행렬로 나누어 학습 (Matrix Fctorization)

[CF 데이터셋 예시]

	M1	M2	МЗ	M4	M5
4	?	1	?	3	?
1	1	?	4	?	3
	3	1	?	?	1
(1)	4	?	5	4	4

[Latent Factor Model]





3. Collaborative Filtering

알고리즘 명점 기반 추천 - SVD 활용(1/2)

보조자료

- Reader, Dataset, SVD, evaluate: collaborative filtering을 위한 surprise 패키지내 함수
- n_folds 지정을 통해 총 5개의 분할된 data set으로 평가 진행
- svd : 특이값 분해

			D	escription	Code
_	실행 결고 ratings	•			from surprise import Reader, Dataset, SVD, evaluate
	userld	movield	rating	timestamp	
0) 1	31	2.5	1260759144	reader = Reader()
1	1	1029	3.0	1260759179	ratings = pd.read_csv('/data/ratings_small.csv')
2	2 1	1061	3.0	1260759182	print(ratings.head())
3	3 1	1129	2.0	1260759185	
4	1	1172	4.0	1260759205	data - Datasat land from df/ratings[[]usarld required
	evaluat	e itiveDefa	ault Dic	t(list, {'rmse': [0.89983 0.8920148802931 0.8959219710584 0.8936678589649 0.9030165249422 'mae': [0.691217 0.6862883096140 0.6932724085733 0.6879949044154 0.6922435122762	svd = SVD()



3. Collaborative Filtering

알고리즘 명점 기반 추천 - SVD 활용(2/2)

보조자료

- svd.train(trainset) : trainset 생성 후 학습 진행
- predict(uid, iid): uid는 사용자 아이디, iid는 영화 아이디

Description	Code
 ✓ 실행 결과 1번 사용자의 302번 영화에 대한 예상 평점 2.710423579738741 3번 사용자의 전체 영화에 대한 예상 평점 정렬 title est Heat 3.263783 GoldenEye 3.180455 Cutthroat Island 3.536884 Casino 3.431532 Sense and Sensibility 3.378550 Four Rooms 2.886416 Get Shorty 3.603110 Leaving Las Vegas 3.269286 The City of Lost Children 3.391873 Twelve Monkeys 2.844785 Dead Man Walking 3.215086 To Die For 3.223957 	<pre>trainset = data.build_full_trainset() svd.train(trainset) a = svd.predict(uid = 1, iid = 302) print(a.est) m_list = list(set(ratings['movield'])) def CF_recsys(id): est_list = [] for mv in m_list: est_list += [svd.predict(id, mv).est] df = pd.DataFrame({'id': m_list, 'est': est_list}).sort_values(by=['est'], ascending=False) df = pd.merge(smd[['title']], df, on='id') return df recs = CF_recsys(3) print(recs)</pre>



4. Hybrid Recommender

이론

Contents based + CF

보조자료

movie_recsys.py

✓ 개념

- (2) Contents Based, (3) Collaborative Filtering 함께 사용
- 두가지 알고리즘을 모두 적용하고, 이의 가중 평균을 구하는 방법(Combining Filtering)
- 평점데이터와 아이템 프로필을 조합하여 사용자 프로필을 만들어 추천(Collaboration via Content)
- ✓ movie recommender에 적용
- input : 사용자 id, 영화 제목
- output : 사용자의 예측평점을 기반한 유사한 영화



4. Hybrid Recommender

알고리즘 Contents based + CF (1/2) 보조자료 movie_recsys.py

- 두개의 다른 데이터셋의 고유 아이디 정의

		Des	criptio
✓ 실행 결과 - id_map movie id 862.0 8844.0 15602.0 31357.0 11862.0 949.0 - indices_m	1 2 3 4 5 6		
	title	movield	id
	Toy Story	1	862.0
	Jumanji	2	8844.0
Grumpie	r Old Men	3	15602.0
Waiting	to Exhale	4	31357.0
Father of the Br	ide Part II	5	11862.0
	Heat	6	949.0



4. Hybrid Recommender

알고리즘

Contents based + CF (2/2)

보조자료

- 2번과 3번의 결과를 바탕으로 hybrid 알고리즘 구현
- 개인별 추천이 달라지는 결과를 보임

Description							Code
✔ 실행 결과 - hybrid(1, 'Avater') title_vote_count_vote_average_yearidest						<pre>def hybrid(userId, title, smd): count = CountVectorizer(analyzer='word', ngram_range=(1, 2), min_df=0, stop_words='english')</pre>	
522		4274.0				3.211401	<pre>idx = indices[title] tmdbId = id_map.loc[title]['id'] movie_id = id_map.loc[title]['movield']</pre>
522	Terminator 2: Judgment Day			1991			
1011	The Terminator	4208.0		1984		3.130996	
974	Aliens	3282.0		1986		3.127167	
8401	Star Trek Into Darkness	4479.0		2013		3.015311	
2014	Fantastic Planet	140.0				2.995867	
3060	Sinbad and the Eye of the Tiger	39.0	6.3	1977	11940	2.934265	# Contents based
- hy	hybrid(500, 'Avatar') title vote_count vote_average year id est				id	sim_scores = list(enumerate(cosine_sim[int(idx)])) sim_scores = sorted(sim_scores, key=lambda x: x[1], reverse=True sim_scores = sim_scores[1:26] movie_indices = [i[0] for i in sim_scores]	
2014	Fantastic Planet	140.0	7.6	1973	16306	3.119180	# Collaborative Filtering movies = smd.iloc[movie_indices][['title', 'vote_count', 'vote_average', 'year', 'id']]
1376	Titanic	7770.0	7.5	1997	597	3.117199	
1621	Darby O'Gill and the Little People	35.0	6.7	1959	18887	3.077525	movies['est'] = movies['id'].apply(lambda x: svd.predict(userId,
1011	The Terminator	4208.0	7.4	1984	218	3.074665	indices_map.loc[x]['movield']).est)
974	Aliens	3282.0	7.7	1986	679	3.052945	movies = movies.sort_values('est', ascending=False)
522	Terminator 2: Judgment Day	4274.0	7.7	1991	280	3.038895	return movies.head(10)
							print(hybrid(1, 'Avatar', smd)) print(hybrid(500, 'Avatar', smd))